

Predictive Maintenance Intelligence

Case de Análise de Dados Industrial para Portfólio

Empresa fictícia: Indústria NovaTech
Segmento: Manufatura industrial
Área: Engenharia de Manutenção / Produção
Objetivo: reduzir paradas não planejadas por meio de análise de dados e manutenção preditiva.

Visão geral

Este projeto foi estruturado como um case empresarial completo, simulando uma demanda real de uma indústria. O objetivo é demonstrar competências de Data Analytics, SQL, Python, Power BI e Machine Learning, sempre conectando os resultados técnicos a decisões de negócio.

Pergunta central do negócio

É possível utilizar os dados operacionais das máquinas para identificar antecipadamente quais equipamentos apresentam maior risco de falha?

1. Problema de negócio

A NovaTech possui máquinas utilizadas continuamente em sua linha de produção. Nos últimos meses, a empresa percebeu aumento das paradas não planejadas, maior custo de manutenção corretiva, perda de produtividade e dificuldade para identificar equipamentos em risco.

A análise deve responder também quais fatores estão mais associados às falhas e como transformar esses achados em ações de manutenção.

2. Objetivos

- Identificar padrões associados às falhas.
- Identificar máquinas com maior risco.
- Prever a probabilidade de falha.
- Identificar os principais fatores que influenciam o risco.
- Disponibilizar os resultados para tomada de decisão.

3. KPIs

KPI	Finalidade
Taxa de falha	Medir a frequência de falhas
Número de falhas	Acompanhar ocorrências
Recall	Priorizar identificação de falhas reais
Precision	Medir qualidade dos alertas
F1-score	Equilibrar precision e recall
ROC-AUC	Avaliar capacidade discriminatória do modelo

KPI	Finalidade
Custo estimado de parada	Traduzir o problema para o negócio
Máquinas em risco	Apoiar a priorização da manutenção

4. Dataset

A primeira versão utiliza o **AI4I 2020 Predictive Maintenance Dataset**, do UCI Machine Learning Repository. O dataset contém 10.000 observações e variáveis relacionadas à operação e às falhas de máquinas.

Principais variáveis: Product ID, Type, Air temperature, Process temperature, Rotational speed, Torque, Tool wear, Machine failure e indicadores de tipos de falha.

Observação: o AI4I é um dataset sintético. Isso deve ser informado claramente no README para evitar a impressão de que são dados confidenciais de uma empresa real.

5. Arquitetura

Dataset → Python/Pandas → Data Cleaning → PostgreSQL → SQL Analytics + EDA → Machine Learning → SHAP/Explainable AI → Power BI → Insights e recomendações.

6. Stack tecnológica

- **Dados:** Python, Pandas, NumPy
- **Banco:** PostgreSQL
- **Análise:** Pandas, Matplotlib, Seaborn
- **Machine Learning:** Scikit-learn, XGBoost, SHAP
- **BI:** Power BI
- **Versionamento:** Git + GitHub

7. Estrutura do GitHub

```
predictive-maintenance/
├── data/raw/
├── data/processed/
├── notebooks/
│   ├── 01_data_exploration.ipynb
│   ├── 02_data_cleaning.ipynb
│   ├── 03_eda.ipynb
│   ├── 04_feature_engineering.ipynb
│   ├── 05_model_training.ipynb
│   └── 06_model_explainability.ipynb
├── sql/
│   ├── 01_database.sql
│   ├── 02_kpis.sql
│   ├── 03_failure_analysis.sql
│   └── 04_machine_risk.sql
├── src/
│   ├── data_processing.py
│   ├── feature_engineering.py
│   └── prediction.py
├── dashboard/predictive_maintenance.pbix
├── models/model.pkl
├── images/dashboard.png
├── requirements.txt
└── README.md
```

8. Etapa 1 — Data Understanding

Antes de modelar, entender o contexto. Perguntas principais: quantas máquinas existem? quais tipos apresentam mais falhas? temperatura, torque, rotação e desgaste influenciam o risco? quais tipos de falha são mais comuns? existem combinações de condições operacionais associadas a maior incidência de falhas?

9. Etapa 2 — Data Cleaning

Verificar valores ausentes, duplicidades, tipos de dados, valores extremos, inconsistências e distribuição das variáveis. Também é essencial investigar **data leakage**. Variáveis diretamente derivadas de eventos de falha não devem ser usadas para prever uma falha futura se elas só ficam disponíveis depois que o evento ocorre.

10. Etapa 3 — EDA

Analisar taxa de falha, falhas por tipo de máquina, desgaste, temperatura, torque, rotação e relações entre variáveis. Criar faixas de desgaste e analisar a taxa de falha em cada faixa. Investigar correlações sem confundir correlação com causalidade.

Perguntas de negócio para a EDA

- Qual é a taxa geral de falha?
- Quais tipos de máquina falham mais?
- A taxa de falha aumenta com o desgaste?
- Existem regiões de temperatura com maior risco?
- Torque e rotação apresentam padrões associados às falhas?
- Quais condições operacionais aparecem com maior frequência antes das falhas?

11. Etapa 4 — SQL

O banco PostgreSQL deve ser utilizado para demonstrar capacidade de transformar perguntas de negócio em consultas analíticas.

```
SELECT
    COUNT(*) AS total_operacoes,
    SUM(machine_failure) AS total_falhas,
    ROUND(100.0 * SUM(machine_failure) / COUNT(*), 2) AS taxa_falha
FROM machine_data;

SELECT
    type,
    COUNT(*) AS total_operacoes,
    SUM(machine_failure) AS falhas,
    ROUND(100.0 * SUM(machine_failure) / COUNT(*), 2) AS taxa_falha
FROM machine_data
GROUP BY type
ORDER BY taxa_falha DESC;
```

12. Etapa 5 — Machine Learning

Objetivo: prever a variável **Machine Failure** utilizando parâmetros operacionais disponíveis antes da falha.

Features iniciais: Air temperature, Process temperature, Rotational speed, Torque e Tool wear.

Modelos: Logistic Regression como baseline, Random Forest e XGBoost para comparação.

O dataset é desbalanceado. Por isso, accuracy isoladamente pode ser enganosa. A avaliação deve considerar principalmente precision, recall, F1-score e ROC-AUC. Em manutenção preditiva, falsos negativos podem ser especialmente caros, então o recall merece atenção.

13. Etapa 6 — Risk Score

Converter a probabilidade estimada pelo modelo em uma classificação operacional simples:

Probabilidade	Classificação
0–30%	Baixo
30–60%	Moderado
60–80%	Alto
80–100%	Crítico

14. Etapa 7 — Explainable AI com SHAP

O modelo deve responder não apenas “qual é o risco?”, mas também “por que o risco é alto?”. SHAP pode mostrar a contribuição de cada variável para uma previsão individual e para o comportamento global do modelo.

Exemplo de apresentação conceitual: previsão de 87% de risco, com Tool Wear, Torque e Process Temperature entre os fatores mais relevantes. Os valores reais devem ser calculados pelo modelo e nunca inventados.

15. Etapa 8 — Power BI

Página 1 — Executive Overview: total de operações, falhas, taxa de falha, máquinas em risco, evolução e principais fatores.

Página 2 — Machine Performance: filtros por tipo, produto e faixas operacionais; torque × rotação, temperatura × falhas e desgaste × falhas.

Página 3 — Failure Analysis: tipos de falha, concentração das ocorrências e condições operacionais associadas.

Página 4 — Predictive Maintenance: ranking de máquinas por risco, probabilidade, fatores explicativos e recomendação de inspeção.

16. Transformação de dados em decisão

A entrega não deve terminar nos gráficos. Cada insight deve ser convertido em uma recomendação de negócio.

Etapa	Exemplo
Insight	Máquinas com alto desgaste e torque elevado concentram maior risco.
Impacto	Essas condições podem contribuir para mais paradas não planejadas.
Recomendação	Priorizar inspeções em máquinas que combinem desgaste, torque e risco preditivo elevados.
Próximo passo	Validar a relação com a equipe de manutenção e históricos reais de intervenção.

17. Roadmap de desenvolvimento

Fase	Entrega
1 — Analytics	Dataset → limpeza → EDA → SQL
2 — BI	PostgreSQL → Power BI → dashboard → insights
3 — ML	Feature engineering → modelos → avaliação
4 — Explainability	SHAP → risk score → recomendações
5 — Portfólio	GitHub → README → screenshots → case study

18. Evolução para Data Science

Depois da primeira versão, o projeto pode evoluir para dados temporais de sensores e para **Remaining Useful Life (RUL)**: estimar quanto tempo de operação resta antes de uma máquina precisar de manutenção. Essa evolução adiciona séries temporais e prognóstico ao case.

19. Como apresentar no currículo

Predictive Maintenance Analytics — Python, SQL, PostgreSQL, Power BI, Machine Learning

Developed an end-to-end predictive maintenance solution using industrial machine data, performing SQL-based analysis, exploratory data analysis, machine failure prediction and explainable AI. Built Power BI dashboards to identify operational risk factors and support preventive maintenance decisions.

20. Mensagem central do projeto

O diferencial do case é demonstrar que Machine Learning não é o fim do projeto. O fluxo completo é: entender o problema industrial → organizar os dados → responder perguntas com SQL e análise exploratória → prever risco → explicar o modelo → comunicar no Power BI → recomendar ações.

Fonte de dados: UCI Machine Learning Repository — AI4I 2020 Predictive Maintenance Dataset.